

아맘때 대기 기간 케어 — 상담을 준비하는 추천 시스템

“AI 개발자 사전 테스트 기획안 · 지원자: 구선모”

1. 문제 정의

보고서 수령 후 상담까지 전문 용어를 해석하기 어려운 보호자의 불안이 누적되고, 반복 문의·상담 이탈·서비스 신뢰 저하로 이어질 수 있다. **관련 칼럼과 관찰 질문으로 대기를 상담 준비 시간으로 전환하는 것이 목표다.**

“AI 검사 결과 → 보호자 수령 → [대기 기간 케어] → 상담사 전화 상담 → 사후 관리”

진단·처방·검사 결과 해석은 상담사가 담당한다. AI는 검수 콘텐츠 추천과 관찰 질문 초안 생성에 활용한다.

2. 기능 설계

기능	보호자 경험
칼럼 추천·예약	수령 당일부터 이틀 간격으로 관련 칼럼 제공
아이별 관찰 질문	칼럼과 아이 검사 수치를 반영한 질문, 선택지 3개·선택적 자유응답
상담 전날 안내	검수 용어 해설집에서 설명 발췌·상담 준비 안내
준비 진행 표시	작은 과제와 완료 표시로 부여된 진전 효과(Endowed Progress Effect) 유도

대기 D일에 따라 `K=max(1, floor(D/2))` 개를 선정하되 발송 슬롯·검수 후보 수로 제한한다. D=6이면 당일·+2일·+4일 칼럼, +5일 용어 설명을 제공한다.

AI로 개발한 프런트는 로그인·칼럼·질문·진행 표시, Convex는 구독·예약·상태 관리, 추론 계층은 Ranker·외부 AI 호출을 담당한다. PoC는 웹 노출·발송 상태 전환까지이며 실제 푸시·이메일·상담사 응답 요약은 후속 범위다.

3. AI 적용 방식 및 활용 지점

3.1 모델 선택 이유

검사 보고서의 수치 크기와 구간 정보는 토큰화된 텍스트 표현으로 옮기는 과정에서 세밀한 값의 차이가 손실될 수 있다. 이를 피하기 위해 원래 수치를 그대로 Ranker에 입력한다. 또한 임상 진단 기준은 특정 cutoff를 경계로 관련도가 달라지는 계단 함수적 성질을 가지므로, 점수에 대한 매끄러운 선형 관계를 가정하는 회귀 모델보다 구간별 분기를 자연스럽게 학습하는 Tree 기반 xgboost.XGBRanker(LambdaMART)가 적합하다고 판단했다.

3.2 칼럼 featurization 방식의 선택 이유

적은 학습 데이터로도 Tree 모델이 활용할 수 있도록, 칼럼의 의미를 사람이 정의한 고정 수치 좌표로 바꾼다. 어휘별 빈도·BM25 벡터는 차원이 크고 희소해, 표현은 달라도 같은 상담 주제를 다루는 글의 관계를 소량 데이터로 학습하기 어렵다. 따라서 텍스트 의미 추출은 사전학습 모델에 맡기고, LambdaMART는 보고서 수치와 칼럼 특성 사이의 추천 관계를 학습한다.

- **기준문서 N개:** ``voyageai/rerank-3`` 로 대표 상담 문서와의 관련도를 계산한다. 주제명뿐 아니라 기준문서에 담긴 구체적인 상황·설명 맥락을 좌표축으로 삼는다.
- **상담유형 M개:** ``typesafe/jev-1.13.0`` 으로 유형별 관련도를 추출한다. 사람이 해석할 수 있는 명시적 주제 축으로, 기준문서의 맥락 축을 보완한다.

사전학습 모델은 “칼럼이 무엇을 다루는가”, LambdaMART는 “어떤 보고서에 적합한가”를 담당한다. 새 칼럼도 같은 축으로 표현하며 사전 계산·캐시한다. 축 밖의 주제는 표현이 부족하므로, 기준문서·유형 목록의 구성이 핵심 **feature engineering**이다.

3.3 입력: 보고서 Q개 + 칼럼 N개 + 칼럼 M개

feature	계산 대상·방법	의미
Q	보고서의 척도별 T점수·백분위 등	보호자별 검사 수치
N	후보 칼럼을 query, 기준문서 N개를 documents로 넣어 rerank	각 기준문서와 후보 칼럼의 관련도
M	칼럼 본문을 state로 두고 Jev에 유형별 독립 질문	각 상담유형을 칼럼이 다루는 정도

기준문서는 상담 전문가가 다양한 상담 양태를 포괄하도록 작성한 대표 칼럼 N개다. **상담유형**은 ADHD, 경계선지능, 내재화 문제 종합, 우울/불안, 사회적 미성숙, 위축 등을 포함한 M개 축으로 정의한다. 유형명은 콘텐츠 관련도 축이며 아이의 진단 결과가 아니다.

보고서 r과 후보 칼럼 d의 입력:

$$x(r, d) = [q_1(r), \dots, q_Q(r), n_1(d), \dots, n_N(d), m_1(d), \dots, m_M(d)]$$

$$\text{입력 차원} = Q + N + M$$

같은 보고서, 다른 칼럼 → 다른 추천 점수

Q · 보고서 수치

후보마다 동일

척도별 수치를 그대로 입력

`[q<sup>1</sup>, q<sup>2</sup>, ..., q<sub>Q</sub> ]`

N · 기준문서 관련도

칼럼의 의미 좌표

기준문서 1  0.82

기준문서 2  0.11

기준문서 3  0.64

reranker로 사전 계산

M · 상담유형 관련도

여러 유형이 함께 높아도 됨

ADHD  0.12

우울/불안  0.81

내재화  0.74

Jev 독립 확률 · 합계 1 제약 없음

LambdaMART 입력 `[보고서 Q | 칼럼 N | 칼럼 M]`

N·M 수치는 설명용 예시 · 아이의 진단 확률이 아님

같은 보고서의 후보는 Q를 공유하고 N·M이 달라진다. Jev는 유형별 독립 $P(\text{relevant})$ 를 사용하며 합계 1로 정규화하지 않는다. 확률과 logit을 구분해 기록한다.

3.4 사전 계산과 추론 분리

비용은 사전 계산에, 개인화는 추천 시점에

① 칼럼 게시 시

텍스트 → 수치

칼럼 본문

reranker · Jev

저장 · 재사용

N · M feature 캐시

축과 모델 버전 고정

② 보고서 수령 시

보고서 Q + 캐시

N · M

후보마다 입력 결합

LambdaMART

개인별 관련도 순위

BM25 다양성

유사 칼럼 감점 · 반복
선택

선정된 K개 칼럼 → 관찰 질문 준비 → 대기 일정에 예약

N · M은 칼럼 게시 시 계산해 캐시하므로 보고서마다 Jev · reranker를 호출하지 않는다. 축 · 본문 · 모델이 변경되면 feature를 갱신하고 버전을 맞춘다. 새 콘텐츠의 추천 품질은 별도 검증한다.

3.5 관련도와 다양성을 함께 고려한 반복 선택

LambdaMART 상위 칼럼만 고르면 유사 주제가 반복될 수 있다. 첫 칼럼을 선택한 뒤, 이미 선택된 칼럼과 BM25 유사도가 높은 후보에 감점을 주어 다음 칼럼을 고른다.

```
score(d) = λ · rel(d | 보고서) - (1-λ) · max_{s ∈ 선택됨} sim(d, s)
```

rel: LambdaMART 점수를 후보 집합 안에서 0~1로 정규화

sim: 칼럼 간 BM25 점수를 0~1로 정규화하고 대칭화

첫 선택은 감점 없이, 이후 선택된 칼럼을 제외하며 K개까지 반복한다. $\lambda=0.7$ 을 초기값으로 두고 validation에서 조정한다. BM25는 다양성 계산에 사용하며 Q+N+M 학습 입력에는 추가하지 않는다.

3.6 학습 파이프라인: 상담 기록 기반 Weak-label 지도학습

가상 상담 보고서도 같은 방식으로 featurization

노트 미제공으로 가상 상담 보고서를 만든다. 칼럼과 상담 보고서 모두 reranker의 기준문서 N개 관련도 + Jev의 상담유형 M개 관련도로 같은 축에 표현한다.

검사 수치 $Q \leftrightarrow$ 상담 보고서 $N+M$ 을 연결하고, 상담 보고서를 유사정답으로 관련 칼럼 retrieve·학습 pair 구성에 활용한다. 상담 보고서·칼럼의 $N \cdot M$ cosine 유사도 순위를 0..3으로 변환해 약한 지도 신호로 사용한다.

학습·검증

1. **축 고정:** $Q \cdot N \cdot M$ 의 순서와 결측 표현을 정한다.
2. **pair 구성:** 상담 보고서의 $N \cdot M$ 을 활용해 관련 칼럼을 연결하고, 검사 보고서별 후보를 ranking query group으로 묶는다.
3. **분할:** 가족·사례 단위 train/validation/test로 동일 사례의 split 간 누출을 막는다.
4. **학습:** `XGBRanker(objective="rank:ndcg")` 를 학습하고 validation으로 설정과 λ 를 조정한다. 학습·추론은 같은 feature 조립 함수를 사용한다.
5. **평가·저장:** test에서 Ranker 단독·다양성 적용을 비교하고 모델·feature 순서·분할·추출 버전·평가 결과를 저장한다.

평가 항목	확인할 내용
NDCG@K	관련 칼럼이 상위에 배치되는가
주제 커버리지·평균 칼럼 유사도	관련도를 유지하면서 중복이 줄어드는가
추론 지연·API 호출 수	사전 계산과 캐시로 요청 비용을 줄였는가

합성 평가는 파이프라인 검증에 한정하며 실제 품질은 상담사·실제 데이터로 확인한다.

3.7 아이 상태를 반영한 질문 생성

Jinja로 질문 생성 지침(system) + 아이 상태·추천 칼럼(user)을 결합해 LLM에 전달한다. 아이 상태는 검사 수치 6개·척도명·결측 여부이며, 없는 나이·최근 행동은 추측하지 않는다. 추천 후 형식·내용 검증을 통과한 아이별 질문을 해당 아이의 예약에 즉시 연결한다. 보호자 응답 이후의 상태 변화는 자동 반영하지 않는다.

4. 개발 산출물

4.1 PoC 구성과 검증

- **데이터·추천:** 가상 상담 데이터, 기주문서·칼럼, feature 생성, LambdaMART 모델
·manifest·관련도/다양성 평가.
- **질문·서비스:** Jinja 템플릿, 질문 생성·검증·개인화 연결, 최소 웹 클라이언트와 Convex 예약 흐름.
- **문서:** 기획안, 직접 작성한 두 설계 문서, 실행·환경 설정 안내.

파일럿에서 제공군·대조군의 **No-show율·대기 중 문의 수**, 콘텐츠 완료율, 상담 전 불안 자기평가, 상담사 유용도를 비교한다.

4.2 직접 설계한 범위와 AI 활용

직접 작성:

``plan.md``, ``plan_training_pipeline.md``의 문제 정의, 리텐션 장치, LambdaMART 선택, Q+N+M feature, BM25 다양성, 가상 상담 데이터와 기주문서·상담유형 설계.
설계 취지 및 추천 시스템 구성에 대한 사항을 중점적으로 직접 핸들링 하였습니다

AI 활용:

frontend/server를 포함한 구현은 AI 적극 활용. 초기 기획안은 Cursor의 Sonnet5.5로 작성한 뒤 불필요한/부정확한 내용을 제거/수정했고, 개발은 OpenAI Codex(GPT6.1-Sol)를 활용했다.
추천 시스템 구성이 기술적 핵심이므로, 다른 부분은 AI에게 맡겼습니다. 이 문서의 가독화/시각화 또한 AI를 활용하였습니다.

5. 리스크 및 대응 방안

리스크	대응
실제 상담 기록 부족	Synthetic data 생성
기준문서·유형 축의 주제 누락	전문가가 범위를 검토하고 축·feature·모델 버전 함께 갱신
칼럼·질문이 불안이나 부담 유발	칼럼 수정·제외, 질문 건너뛰기·자유응답 선택 허용
API·질문 검증 실패·예약 중복/취소	공통 검수 질문 fallback, 중복 처리 방지·재시도·취소 확인

6. 운영 비용/성능 trade-off

- **칼럼별 N·M:** 칼럼을 새로 등록할 때 마다 N번의 reranker, M개의 Jev API 사용이 발생하기 때문에, 칼럼 수에 비례하는 변동비용이 발생한다. N·M의 수는 많을수록 좋은 것이 아니라, 성능 상 최적화가 필요한 부분이다.
- **LambdaMART 추론서버:** 활성 유저 수를 고려하여 클라우드에서 GPU/CPU 인스턴스 중 하나를 선택할 필요가 있다. 고정비용 성격.
- **보고서/칼럼 별 질문 생성:** 활성 유저가 많다면 가장 많은 비용이 발생할 수 있는 부분이다. 현재 보고서-칼럼 pair 수에 비례하여 호출 횟수가 정해지지만, 비용 절감이 필요하다면 칼럼 별 고정된 질문 set을 구성하는 방법을 선택할 수도 있다.